

PROJECT PROPOSAL
“IDENTIFIKASI TINGKAT KATA KASAR BERBAHASA INDONESIA
DALAM PLATFORM MEDIA SOSIAL BERBASIS TEKS”
NATURAL LANGUAGE PROCESSING

BAB 1. PENDAHULUAN

1.1. Latar Belakang

Komunikasi melalui media sosial telah menjadi metode yang paling umum digunakan oleh masyarakat modern. Platform berbasis teks seperti X (Twitter), Threads, dan Reddit, serta fitur komentar di Instagram, YouTube, dan TikTok, mendorong interaksi verbal yang masif di dunia digital. Fenomena ini turut membawa dampak negatif berupa penyebaran abusive language dan kata-kata kasar yang marak digunakan, terutama di kalangan generasi Z.

Wilie dkk. (2020) mencatat bahwa bahasa Indonesia merupakan bahasa keempat terbanyak digunakan di internet, dengan lebih dari 171 juta pengguna aktif. Namun, perkembangan riset NLP untuk bahasa Indonesia jauh tertinggal dibandingkan bahasa Inggris akibat keterbatasan sumber daya dan dataset. Koto dkk. (2020) mempertegas kondisi ini dengan menyatakan bahwa meskipun bahasa Indonesia dituturkan oleh hampir 200 juta orang dan termasuk 10 bahasa paling banyak digunakan di dunia, representasinya dalam riset NLP masih sangat minim.

Ibrohim dan Budi (2019) menunjukkan bahwa hate speech dan bahasa abusif di media sosial Indonesia perlu dideteksi secara otomatis untuk mencegah konflik antar pengguna. Tantangan utama dalam deteksi kata kasar berbahasa Indonesia adalah adanya variasi penulisan, penyamaran karakter (contoh: ‘anjing’ → ‘4nj!ng’), dan ambiguitas kontekstual pada kata bermakna ganda. Sementara itu, Devlin dkk. (2019) memperkenalkan arsitektur BERT yang terbukti mengungguli metode klasifikasi teks tradisional di berbagai benchmark NLP, sehingga membuka jalan bagi pengembangan model serupa untuk bahasa-bahasa lain, termasuk bahasa Indonesia.

Penelitian ini mengusulkan sistem identifikasi dan klasifikasi tingkat kata kasar berbahasa Indonesia ke dalam empat kelas (0–3) menggunakan pendekatan berbasis leksikon, machine learning tradisional (Naive Bayes dan Logistic Regression), dan model bahasa berbasis transformer (IndoBERTweet). Penelitian ini relevan karena memanfaatkan dataset yang bersumber dari teks media sosial berbahasa Indonesia yang aktual, sekaligus membandingkan metode sederhana dan canggih secara sistematis.

1.2. Rumusan Masalah

Penelitian ini merumuskan permasalahan sebagai berikut:

1. Bagaimana cara mengidentifikasi kata-kata kasar dalam teks berbahasa Indonesia pada platform media sosial?
2. Bagaimana menangani variasi penulisan dan penyamaran kata kasar yang dilakukan pengguna?
3. Bagaimana membedakan kata yang bersifat kasar dan kata yang bermakna netral dalam konteks kalimat yang berbeda?

1.3. Tujuan

Penelitian ini memiliki beberapa tujuan utama sebagai berikut:

1. Mengidentifikasi kata-kata kasar pada teks;
2. Menerapkan Natural Language Processing dalam proses identifikasi;

BAB 2. TINJAUAN PUSTAKA

2.1. *Natural Language Processing* (NLP)

Natural Language Processing adalah bidang keilmuan yang membuat mesin mampu untuk memahami, menginterpretasikan, dan menghasilkan bahasa manusia (LLC, 2025, 27). Sedangkan menurut Apriliani, dkk. (2023), *Natural Language Processing* adalah cabang dari *Artificial Intelligence* yang membantu komputer membaca dan memahami bahasa alami manusia. Dalam konteks penelitian ini, NLP diterapkan untuk mendeteksi dan mengklasifikasikan kata kasar pada teks berbahasa Indonesia dari platform media sosial.

2.2. Deteksi Bahasa Abusif dan Hate Speech

Penelitian deteksi bahasa abusif dan *hate speech* di media sosial telah berkembang pesat. Ibrohim dan Budi (2019) memublikasikan dataset multi-label *hate speech* berbahasa Indonesia dari Twitter, yang menjadi salah satu benchmark utama untuk penelitian serupa. Dataset ini mencakup 13.126 tweet yang dianotasi dengan label bertingkat, termasuk level HS_Weak, HS_Moderate, dan HS_Strong. Pada eksperimennya, model Random Forest Decision Tree (RFDT) dengan metode transformasi Label Power-set menghasilkan akurasi tertinggi.

2.3. Klasifikasi Empat Kelas vs. Klasifikasi Biner

Penelitian deteksi *hate speech* sebagian besar menggunakan klasifikasi biner (abusif / tidak abusif). Namun, Ibrohim dan Budi (2019) menunjukkan bahwa klasifikasi bertingkat (*multi-level*) lebih informatif karena membantu otoritas dalam

memprioritaskan penanganan *hate speech* berdasarkan tingkat keparahannya. Penelitian ini mengadopsi pendekatan empat kelas (0 = nihil, 1 = rendah, 2 = menengah, 3 = tinggi) yang memberikan granularitas lebih tinggi dibanding klasifikasi biner, sekaligus tetap dapat diimplementasikan dengan model yang ada. Kelima kelas lebih dari empat akan memperbesar risiko *class imbalance* yang parah dan menurunkan performa model secara signifikan, sehingga empat kelas dipilih sebagai keseimbangan antara granularitas dan kelayakan teknis.

2.4. Preprocessing Teks Bahasa Indonesia

Prahasto dan Setiawan (2025) menggunakan PySastrawi dalam proses *stemming* dan penghapusan *stopwords* untuk teks bahasa Indonesia dalam analisis sentimen Twitter. Penelitian tersebut menunjukkan bahwa tahap *stemming* berkontribusi pada peningkatan performa model Bi-LSTM. *Stemming* dipilih dibanding *lemmatization* karena kata dalam bahasa Indonesia mengalami penambahan imbuhan, bukan perubahan bentuk kata seperti dalam bahasa Inggris.

Das dkk. (2022) membandingkan TF-IDF dan *Count Vectorization* sebagai metode ekstraksi fitur untuk klasifikasi teks. Hasilnya menunjukkan bahwa TF-IDF dengan pendekatan *N-gram* menghasilkan performa yang lebih baik dibanding *Count Vectorization* pada berbagai klasifier, termasuk Logistic Regression. Temuan ini memperkuat penggunaan TF-IDF berbasis *character n-gram* dalam penelitian ini.

2.5. Model Yang Digunakan

Dalam penelitian ini digunakan beberapa pendekatan utama dalam klasifikasi teks, yaitu metode machine learning tradisional dan metode berbasis deep learning. Model yang digunakan dalam project ini adalah Logistic Regression, Naive Bayes, Support Vector Machine (SVM), dan IndoBERT. Pemilihan keempat model ini bertujuan untuk membandingkan performa antara metode tradisional berbasis fitur TF-IDF dengan metode berbasis transformer dalam mendeteksi kata-kata kasar berbahasa Indonesia.

2.5.1. Logistic Regression

Logistic Regression merupakan algoritma klasifikasi linear yang digunakan untuk memprediksi probabilitas suatu data termasuk ke dalam kelas tertentu. Dalam konteks klasifikasi teks, model ini bekerja dengan mempelajari hubungan antara fitur-fitur teks dengan label yang diberikan.

Pada penelitian ini, Logistic Regression digunakan dengan representasi fitur berupa TF-IDF, khususnya dengan pendekatan *character n-gram*. Pendekatan ini

memungkinkan model untuk mengenali pola penulisan kata kasar, termasuk yang telah dimodifikasi atau disamarkan.

2.5.2. Naive Bayes

Naive Bayes merupakan algoritma klasifikasi berbasis probabilitas yang menggunakan Teorema Bayes dengan asumsi bahwa setiap fitur bersifat independen. Model ini banyak digunakan dalam klasifikasi teks karena memiliki keunggulan dalam hal kecepatan dan efisiensi dalam komputasi.

Dalam konteks penelitian ini, Naive Bayes mengklasifikasikan teks berdasarkan fitur yang diekstraksi menggunakan metode seperti *Bag of Words* atau *TF-IDF*. Model ini sering memberikan hasil yang cukup baik untuk permasalahan klasifikasi teks.

Model ini bekerja secara efektif dalam mengenali kata-kata kasar yang muncul secara eksplisit dalam teks, namun memiliki keterbatasan dalam memahami konteks kalimat secara keseluruhan.

2.5.3. Support Vector Machine (SVM)

Support Vector Machine (SVM) merupakan algoritma machine learning yang digunakan untuk melakukan klasifikasi dengan mencari hyperplane optimal yang dapat memisahkan data ke dalam kelas-kelas tertentu. Dalam klasifikasi teks, SVM dikenal memiliki performa yang baik karena mampu menangani data berdimensi tinggi seperti representasi TF-IDF secara efektif.

Pada penelitian ini, SVM digunakan untuk mengklasifikasikan tingkat kata kasar berdasarkan fitur TF-IDF yang dihasilkan dari tahap preprocessing. SVM bekerja dengan mencari batas pemisah terbaik antar kelas sehingga dapat membedakan tingkat kekasaran teks dengan lebih optimal.

SVM dipilih karena algoritma ini sering digunakan dalam berbagai tugas Natural Language Processing seperti sentiment analysis, spam detection, dan hate speech detection. Dibandingkan Naive Bayes dan Logistic Regression, SVM memiliki kemampuan generalisasi yang baik pada data teks dengan jumlah fitur yang besar. Namun, model ini tetap memiliki keterbatasan dalam memahami konteks kalimat dibandingkan model berbasis transformer seperti IndoBERT.

2.5.4. IndoBERT

Devlin dkk. (2019) memperkenalkan BERT (*Bidirectional Encoder Representations from Transformers*), model bahasa *transformer* yang dilatih

secara bidireksional menggunakan teks tidak berlabel. BERT terbukti mencapai performa *state-of-the-art* pada 11 tugas NLP, termasuk klasifikasi teks. Arsitektur ini kemudian diadaptasi untuk berbagai bahasa, termasuk bahasa Indonesia.

Koto dkk. (2020) mengembangkan IndoBERT, model bahasa berbasis BERT yang dilatih khusus untuk bahasa Indonesia menggunakan lebih dari 220 juta kata. Model ini memiliki 12 *hidden layers*, 768 dimensi, dan 12 *attention heads*. IndoBERT terbukti mengungguli model multilingual dan Word2Vec pada berbagai tugas NLP bahasa Indonesia dalam benchmark IndoLEM.

Wilie dkk. (2020) memperkenalkan IndoNLU, benchmark komprehensif pertama untuk bahasa Indonesia yang mencakup 12 tugas NLP. Model IndoBERT yang dievaluasi pada IndoNLU (varian *indobert-base-pl*) secara konsisten melampaui baseline FastText dan model multilingual. Benchmark ini menjadi standar evaluasi untuk model NLP berbahasa Indonesia.

Koto dkk. (2021) mengembangkan IndoBERTtweet, model bahasa berbasis IndoBERT yang diadaptasi khusus untuk teks Twitter berbahasa Indonesia menggunakan 26 juta tweet. Berbeda dari IndoBERT umum, IndoBERTtweet dilatih dengan kosakata domain-spesifik yang diinisialisasi menggunakan rata-rata *subword embedding* BERT, sehingga lima kali lebih efisien dibanding pelatihan dari awal. Karena dataset penelitian ini dominan bersumber dari media sosial (Twitter/X, Threads), IndoBERTtweet dipilih sebagai model utama dalam penelitian ini.

2.6. Library dan Tools

2.6.1. NLTK

NLTK (*Natural Language Toolkit*) merupakan salah satu *library* Python yang digunakan untuk pemrosesan bahasa alami (*Natural Language Processing*). *Library* ini menyediakan berbagai fungsi untuk membantu pengolahan teks, seperti tokenisasi, penghapusan stopwords, serta analisis linguistik dasar. Dalam penelitian ini, NLTK digunakan terutama pada tahap preprocessing data teks. Fungsi utama NLTK yang dimanfaatkan adalah:

1. Tokenisasi

Tokenisasi adalah proses memecah kalimat menjadi unit-unit kecil berupa kata (token). Proses ini penting agar teks dapat dianalisis lebih lanjut oleh model.

Contoh: “Indonesia lagi macet parah” = [“Indonesia”, “lagi”, “macet”, “parah”]

2. *Stopwords Removal*

NLTK menyediakan daftar kata umum (stopwords) yang sering muncul tetapi tidak memiliki makna signifikan seperti “dan”, “yang”, “di”. Penghapusan stopwords bertujuan untuk mengurangi noise dalam data.

3. *Text Processing Support*

NLTK juga membantu dalam pengolahan teks dasar seperti normalisasi dan integrasi dengan pipeline lainnya.

2.6.2. PySastrawi

PySastrawi adalah sebuah *library* Python yang digunakan untuk membantu menghapus *stopwords* dan melakukan *stemming*. (Prahasto & Setiawan, 2025, 22) Pada penelitian ini PySastrawi digunakan pada tahap *text preprocessing*. PySastrawi digunakan untuk melakukan *stopword removal*, ini bertujuan untuk mengurangi dimensi data dengan menghapus kata yang tidak memiliki kontribusi terhadap sentimen, seperti kata ganti benda, konjungsi dan preposisi. Selain itu, pada penelitian ini PySastrawi digunakan untuk melakukan *stemming* terhadap data, yaitu mengonversi kata berimbuhan menjadi bentuk dasarnya.

2.6.3 Rapidfuzz

RapidFuzz merupakan salah satu *library* Python yang digunakan untuk melakukan fuzzy string matching, yaitu metode yang digunakan untuk mengukur tingkat kemiripan antara dua string meskipun tidak memiliki kesamaan secara persis. Teknik ini sangat berguna dalam pengolahan teks yang mengandung variasi penulisan atau perubahan karakter.

Dalam penelitian ini, RapidFuzz dimanfaatkan untuk mendeteksi kata-kata kasar yang telah mengalami modifikasi atau penyamaran. Pada platform media sosial, pengguna sering kali mengubah penulisan kata kasar dengan tujuan menghindari sistem moderasi, contohnya dengan mengganti huruf dengan angka, menambahkan karakter berulang, atau menghilangkan beberapa huruf dalam kata tersebut.

Metode *exact matching* tidak mampu menangani kasus seperti ini secara efektif. Oleh karena itu, RapidFuzz digunakan untuk menghitung tingkat kemiripan antara kata dalam teks dengan kata-kata dalam kamus kasar. Apabila nilai kemiripan melebihi ambang batas tertentu, maka kata tersebut dapat

diidentifikasi sebagai bentuk variasi dari kata kasar yang dimaksud. Dengan demikian, penggunaan RapidFuzz dalam penelitian ini berperan sebagai pelengkap dalam tahap *preprocessing*, khususnya dalam meningkatkan kemampuan sistem untuk mengenali kata kasar yang tidak dituliskan secara baku.

2.7. AutoTokenizer (Hugging Face)

AutoTokenizer adalah komponen dari *library* Hugging Face Transformers yang digunakan untuk melakukan proses tokenisasi teks secara otomatis sesuai dengan model yang digunakan. Tokenisasi adalah proses mengubah teks menjadi token, yang kemudian akan diproses oleh model machine learning. Berbeda dengan metode tokenisasi tradisional, AutoTokenizer menggunakan pendekatan subword tokenization, yaitu memecah kata menjadi bagian-bagian yang lebih kecil berdasarkan struktur yang telah dipelajari sebelumnya oleh model. Pendekatan ini memungkinkan sistem untuk tetap memahami kata-kata yang tidak terdapat dalam kamus, termasuk kata tidak baku atau kaya yang telah dimodifikasi.

Dalam penelitian ini, AutoTokenizer digunakan bersama model IndoBERT untuk memastikan bahwa proses tokenisasi sesuai dengan format yang diharapkan oleh model tersebut. Hal ini penting karena setiap model berbasis *transformer* memiliki aturan tokenisasi yang berbeda, sehingga penggunaan tokenizer yang sesuai akan mempengaruhi performa model secara signifikan. AutoTokenizer juga menangani proses tambahan seperti pemberian indeks numerik pada token, penambahan token khusus, serta penyesuaian panjang input melalui *padding* dan *truncation*. AutoTokenizer berperan penting dalam menjembatani data teks mentah menjadi input yang dapat diproses oleh model IndoBERT.

2.9. Scikit-Learn (Metrik Evaluasi)

Manning dkk. (2008) menjelaskan bahwa F1-score merupakan rata-rata harmonik dari precision dan recall, sehingga memberikan keseimbangan antara kedua metrik tersebut. F1-score sangat relevan untuk dataset yang tidak seimbang karena tidak dipengaruhi oleh jumlah sampel kelas mayoritas. Selain F1-score, confusion matrix digunakan untuk menganalisis distribusi kesalahan klasifikasi per kelas secara detail (Sokolova & Lapalme, 2009).

Scikit-learn, yang sering disebut sklearn adalah sebuah *library open-source* berbasis bahasa pemrograman Python yang dirancang untuk menyederhanakan implementasi model Machine Learning. Scikit-learn memiliki modul penting yang sering digunakan

dalam pembuatan Machine Learning seperti, klasifikasi, regresi, dan clustering. Scikit-learn dibangun menggunakan fondasi library Python lainnya, seperti NumPy untuk pemrosesan *array*, SciPy untuk algoritma matematika tingkat lanjut, dan Matplotlib untuk visualisasi data. Penelitian ini menggunakan Scikit-learn untuk melakukan evaluasi model, scikit-learn menyediakan serangkaian metrik bawaan sehingga membantu dalam proses evaluasi model. Metrik evaluasi yang digunakan adalah *F1-score*, yaitu rata-rata harmonik dari presisi dan *recall*. Metrik *F1-score* dipilih karena memberikan keseimbangan antara metrik presisi dan *recall* ini.

BAB 3. Pengerjaan Proyek

3.1. Pengumpulan Dataset

Dataset yang digunakan untuk melatih model AI dibagi menjadi data primer dan sekunder. Data primer didapatkan melalui *web scraping* dari situs media sosial Reddit, Thread, dan X. *Scraping* menggunakan *library* Python Selenium dan menargetkan *post* yang berhubungan dengan Indonesia secara umum. Beberapa *tag* yang digunakan dalam pencarian meliputi “Timnas Indonesia”, “Politik Indonesia”, “Macet Jakarta”, “Harga naik”, “Makan bergizi gratis”, dan “lang:id”.

Data sekunder diambil dari dataset yang dipublikasikan secara *open source* pada Kaggle. Dataset sekunder ini terdiri atas kalimat-kalimat dalam bahasa Indonesia dari platform X (Twitter) yang diambil pada tahun 2019 dan dapat diakses melalui tautan: <https://www.kaggle.com/datasets/ilhamfp31/indonesian-abusive-and-hate-speech-twitter-text>. Dataset tersebut telah dilabeli dengan kolom-kolom berikut

1. HS: *hate speech label*;
2. Abusive: *abusive language label*;
3. HS_Individual: *hate speech targeted to an individual*;
4. HS_Group: *hate speech targeted to a group*;
5. HS_Religion: *hate speech related to religion/creed*;
6. HS_Race: *hate speech related to race/ethnicity*;
7. HS_Physical: *hate speech related to physical/disability*;
8. HS_Gender: *hate speech related to gender/sexual orientation*;
9. HS_Gender: *hate related to other invective/slander*;
10. HS_Weak: *weak hate speech*;
11. HS_Moderate: *moderate hate speech*;
12. HS_Strong: *strong hate speech*.

Data dari kedua sumber digabungkan dan dilabeli ulang menggunakan skema anotasi yang seragam. Data final disimpan dalam file .csv dengan kolom ["Kalimat Asli", "Kalimat Dinormalisasi", "Level Kata Kasar", "Disamarkan"]. Label "Level Kata Kasar" dibagi menjadi empat level seperti dijelaskan pada Tabel 1 berikut.

Level	Tingkat Kekasaran	Deskripsi	Contoh kata
0	Nihil	Bukan kata kasar	-
1	Rendah	Sering digunakan dalam percakapan sehari-hari, dapat menimbulkan ketidaknyamanan ringan. Tidak menyerang pihak lain secara personal maupun kelompok, tidak eksplisit, dan tidak menyinggung ras atau agama. Kata pada level ini tidak memiliki makna ganda sebagai kata biasa sehingga aman untuk dimasukkan ke dalam leksikon.	Bego, goblok, tolol, idiot, bodoh, dungu, sinting, edan, gila, kampungan
2	Menengah	Menimbulkan ketidaknyamanan jika digunakan di ruang publik dan menyinggung pihak lain secara langsung, namun tidak eksplisit maupun menyinggung ras atau agama.	Anjing, bangsat, bajingan, brengsek, keparat, sialan, kurang ajar, babi, kampret, asu, celaka,
3	Tinggi	Menyerang individu/kelompok/ras lain, mengandung konten eksplisit	Jancok / jancuk, kontol, memek, asu, dancok, lonte, pelacur

Tabel 1. Penjelasan level tingkat kata kasar

Catatan penting mengenai Tabel 1: kata-kata seperti ‘gila’, ‘edan’, ‘anjing’, dan ‘babi’ tidak dimasukkan ke dalam level manapun pada leksikon karena memiliki makna ganda. Kata-kata tersebut ditangani secara kontekstual oleh model IndoBERT pada tahap klasifikasi (lihat Bagian 3.3.1 dan 3.3.2 untuk penjelasan lebih lanjut).

Label “Disamarkan” bermaksud untuk menandai kalimat yang mengandung kata kasar dengan disamarkan menggunakan kombinasi huruf, simbol, dan angka (contohnya:

‘anjing’ -> ‘4nj!ng’). Nilai 0 menyatakan bahwa tidak ada kata kasar yang disamarkan, sedangkan 1 menyatakan terdapat kata kasar yang disamarkan.

3.2. Penanganan *Class Imbalance*

Chawla dkk. (2002) memperkenalkan SMOTE (*Synthetic Minority Oversampling Technique*), metode oversampling yang menghasilkan sampel sintetis pada kelas minoritas menggunakan interpolasi linear antara sampel terdekat. Meskipun sangat populer, SMOTE memerlukan komputasi yang lebih kompleks dibanding *random oversampling* dan dapat menghasilkan *noise* pada data teks.

Zhang dkk. (2024) membandingkan 10 metode penanganan *class imbalance* pada deteksi bahasa abusif. Hasilnya menunjukkan bahwa untuk dataset multi-kelas berukuran kecil hingga menengah, *random oversampling* memberikan hasil yang kompetitif dengan kompleksitas implementasi yang jauh lebih rendah. Oleh karena itu, penelitian ini menggunakan *random oversampling* (duplikasi acak sampel kelas minoritas) sebagai pendekatan yang lebih sederhana dan mudah diterapkan oleh pemula.

3.3. *Preprocessing*

Preprocessing atau pengolahan data dilakukan untuk memastikan data siap diproses lebih lanjut. Tahapan ini dibagi menjadi 7 tahapan dengan proses sebagai berikut:

3.3.1. Deteksi Penyamaran

Bagian ini menerapkan RegEx untuk mendeteksi adanya kata yang disamarkan menggunakan karakter non-alfanumerik dan angka pada data yang belum di *preprocess*. Berikut adalah *pattern* RegEx yang digunakan: `[0-9@!$.|]`. Kalimat yang mengandung karakter sesuai *pattern* RegEx tersebut kemudian akan dilabeli dengan angka 1 di kolom ‘Disamarkan’.

3.3.2. Lowercasing

Menggunakan fungsi `.lower()` pada Python untuk memastikan seluruh kalimat yang diambil dari dataset memiliki format yang selaras.

3.3.3. Penghapusan spasi berlebih

Setiap spasi yang membentuk pola berulang (contohnya ‘a n j i n g’) akan dihapus untuk digabungkan menjadi satu kesatuan kata yang utuh. *Regular expression* digunakan sebagai berikut: `(?<!\w) (\w\s){2,} \w (?!\w)`.

3.3.4. Pembersihan tanda baca

Menggunakan *regular expression* dengan format `(?<=[a-z])[\.\-_'";"]` `(?=[a-z])` untuk menghilangkan tanda baca seperti titik (.), strip (-), dan garis bawah (_), dan lainnya yang jarang muncul sebagai substitusi huruf dalam suatu kata kasar. Adapun tanda baca seperti asteris (*), seru (!), dan arroba (@) tidak dibersihkan karena sering muncul dalam kata kasar.

3.3.5. Substitusi tanda baca dan angka

Sisa tanda baca dan angka yang umum muncul sebagai substitusi dari huruf dikonversi kembali ke bentuk huruf.

3.3.6. Tokenisasi

Mengubah kalimat menjadi token-token yang berupa kata. Proses ini menggunakan tokenizer yang disediakan oleh Library Python PySastrawi.

3.3.7 Stemming

Menghapus imbuhan pada suatu kata sehingga kembali ke bentuk dasarnya (misal: ‘mengambil’ -> ‘ambil’) agar kata-kata dengan makna sama digabungkan menjadi suatu kesatuan. Tahapan ini dilakukan dengan bantuan Library Python ‘PySastrawi’. Pada kasus ini, *stemming* digunakan ketimbang *lemmatizing* karena kata dalam bahasa Indonesia tidak mengalami perubahan kata seperti pada bahasa Inggris, melainkan hanya mendapatkan imbuhan.

3.4. Feature Extraction

Data yang telah melewati tahap *preprocessing* kemudian diubah ke dalam bentuk fitur yang dapat dipahami oleh model. Tahap ini dilakukan menggunakan 2 metode utama, yakni Lexicon dan LLM-Assisted Labelling.

3.4.1. Lexicon Kata Kasar

Lexicon berisi daftar kata-kata kasar yang telah diberikan, beserta dengan tingkat kekasarannya. Dalam tabel lexicon tersebut, kata-kata dengan makna ganda tidak dimasukkan demi mencegah kesalahan konteks. Token diberi label berdasarkan kata-kata dalam tabel lexicon untuk mempercepat proses awal. Beberapa kata yang dimasukkan ke lexicon seperti ‘bangsat’, ‘tolol’, ‘kontol’, dan ‘bajingan’. Kata-kata dengan makna ganda seperti ‘anjing’, ‘kampung’, dan ‘jawa’ tidak dimasukkan ke dalam lexicon karena memiliki kemungkinan digunakan dalam konteks lain.

3.4.2. LLM-Assisted Labelling

Kata-kata yang belum mendapatkan label dari leksikon diolah menggunakan LLM-Assisted Labelling untuk memastikan seluruh data mendapatkan anotasi yang tepat. Dalam konteks ini, model bahasa besar (seperti GPT-4o-mini) digunakan untuk menangkap konteks yang terdapat dalam suatu kalimat sebelum diberikan label. Variabel tingkat kekasaran menggunakan Tabel 1.

3.4.3. Ekstraksi Fitur TF-IDF

Untuk model Naive Bayes dan Logistic Regression, teks yang telah diproses diubah menjadi representasi numerik menggunakan metode TF-IDF (Term Frequency-Inverse Document Frequency) dari scikit-learn. TF-IDF mengukur seberapa penting suatu kata dalam sebuah dokumen relatif terhadap seluruh korpus. Representasi ini digunakan sebagai input langsung ke kedua model tradisional tersebut. IndoBERT tidak menggunakan TF-IDF — model ini menerima token dari AutoTokenizer dan menghasilkan representasi embedding kontekstualnya sendiri.

3.5. Model

Pada proyek ini digunakan tiga pendekatan model, yaitu Logistic Regression dan Naive Bayes sebagai machine learning tradisional dan IndoBERT sebagai deep learning dan juga memakai SVM. Naive Bayes dan IndoBERT digunakan untuk melakukan klasifikasi teks ke dalam empat kategori tingkat kasar. Berikut adalah perbandingan ketiga model tersebut

Aspek	Naive Bayes / Logistic Regression	IndoBERT	Support Vector Machine (SVM)
Pendekatan	Machine Learning tradisional berbasis probabilitas	Deep learning berbasis Transformer	Machine Learning berbasis margin classifier
Input fitur	TF-IDF (representasi numerik frekuensi kata)	Embedding kontekstual dari AutoTokenizer	TF-IDF (representasi numerik frekuensi kata)
Pemahaman konteks	Tidak — setiap kata dianggap independen	Ya — memahami hubungan antar kata secara dua arah	Tidak — berbasis pemisahan fitur
Kecepatan pelatihan	Sangat cepat	Lebih lambat, memerlukan GPU	Cepat hingga menengah

Performa umum	Baik sebagai baseline	Lebih tinggi, terutama untuk kata ambigu	Sangat baik pada data teks berdimensi tinggi
----------------------	-----------------------	--	--

Tabel 2. Perbandingan karakteristik model

3.5.1. Logistic Regression

Logistic Regression dilatih menggunakan representasi TF-IDF dari teks yang telah di *preprocess*. Model ini menghasilkan output berupa label klasifikasi dengan nilai 0 hingga 3 yang menunjukkan tingkat kekasaran. Logistic Regression berfungsi sebagai baseline pertama dan dibandingkan dengan Naive Bayes serta IndoBERT menggunakan metrik F1-score.

3.5.2. Naive Bayes Classifier

Naive Bayes dilatih menggunakan representasi TF-IDF yang sama dengan Logistic Regression. Berdasarkan probabilitas kemunculan fitur dalam setiap kelas, model mengklasifikasikan teks ke dalam salah satu dari empat tingkat kekasaran (0–3). Meskipun asumsi independensi antar fitur menyederhanakan realitas, Naive Bayes umumnya memberikan performa yang kompetitif pada klasifikasi teks dan berfungsi sebagai baseline kedua dalam proyek ini.

3.5.3. Support Vector Machine (SVM)

Support Vector Machine (SVM) dilatih menggunakan representasi TF-IDF dari teks yang telah melalui tahap preprocessing. Model ini bekerja dengan mencari hyperplane optimal yang dapat memisahkan data antar kelas secara maksimal. Berdasarkan fitur-fitur teks yang diberikan, SVM mengklasifikasikan teks ke dalam empat tingkat kekasaran, yaitu level 0 hingga level 3.

Pada penelitian ini, SVM digunakan sebagai model pembanding tambahan terhadap Logistic Regression, Naive Bayes, dan IndoBERT. SVM dipilih karena memiliki performa yang baik pada klasifikasi teks berdimensi tinggi dan sering digunakan dalam tugas seperti hate speech detection dan sentiment analysis.

3.5.3. IndoBERT

Teks yang telah di *preprocess* diubah menjadi token menggunakan AutoTokenizer dari Hugging Face yang spesifik untuk model IndoBERT. Token yang dihasilkan dikonversi menjadi embedding kontekstual dan diproses oleh model IndoBERT untuk memahami konteks kalimat secara keseluruhan. IndoBERT kemudian di-fine-tune menggunakan dataset yang telah dianotasi untuk tugas klasifikasi empat kelas (0–3). Output akhir berupa label klasifikasi tingkat kekasaran beserta skor kepercayaan (confidence score).

Keunggulan utama IndoBERT dibanding kedua model tradisional adalah kemampuannya memahami konteks kata. Kata ‘anjing’ dalam kalimat ‘anjing saya sakit’ akan menghasilkan representasi embedding yang berbeda dibanding ‘anjing’ dalam kalimat ‘dasar anjing lu!’, sehingga model dapat membedakan makna netral dan makna kasar dari kata yang sama.

3.6. Evaluasi *Output*

Evaluasi model dilakukan untuk mengukur performa keempat model dalam mengklasifikasikan tingkat kata kasar pada teks. Dataset dibagi menjadi data latih dan data uji dengan perbandingan 80:20. Terdapat dua metode evaluasi yang digunakan dalam penelitian ini, yaitu F1-Score dan Confusion Matrix.

3.6.1. F-1 Score

Metode evaluasi utama yang digunakan adalah F1-Score karena metrik ini mampu memberikan keseimbangan antara precision dan recall, terutama dalam kasus klasifikasi data yang tidak seimbang (imbalanced). Precision mengukur seberapa banyak prediksi positif yang benar-benar positif, sedangkan recall mengukur seberapa banyak data positif yang berhasil terdeteksi oleh model.

F1-Score dihitung untuk setiap kelas (0, 1, 2, dan 3) dan dilaporkan menggunakan macro-average untuk memberikan gambaran keseluruhan performa model secara merata pada setiap kelas.

3.6.1. Confusion Matrix

Confusion matrix digunakan untuk melihat distribusi hasil prediksi model terhadap masing-masing kelas secara detail. Dengan confusion matrix, dapat dianalisis jenis kesalahan klasifikasi yang dilakukan oleh model, misalnya apakah model cenderung mengklasifikasikan teks level 2 sebagai level 1 atau sebaliknya.

Evaluasi dilakukan pada keempat model, yaitu Logistic Regression, Naive Bayes, Support Vector Machine (SVM), dan IndoBERT untuk membandingkan performa masing-masing model secara komprehensif dalam mendeteksi tingkat kata kasar pada teks berbahasa Indonesia. Hasil evaluasi ini digunakan untuk menentukan model yang paling efektif dalam penelitian ini.

DAFTAR PUSTAKA

- Apriliani, D., Handayani, S. F., & Saputra, I. T. (2023). Implementasi Natural Language Processing (NLP) Dalam Pengembangan Aplikasi Chatbot Pada SMK YPE Nusantara Slawi. *Techno.com*, 22(4), 1037–1047. <https://pdfs.semanticscholar.org/07c7/bd164462bd42d18c34cd38bf15472645dfe7.pdf>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Das, M., Kamalanathan, S., & Alphonse, P. J. A. (2022). A Comparative Study on TF-IDF feature weighting method and its analysis using unstructured dataset. *Proceedings of the International Conference on Computing, Communication and Learning*. <https://arxiv.org/abs/2308.04037>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)* (pp. 4171–4186). Association for Computational Linguistics. <https://aclanthology.org/N19-1423/>
- Ibrohim, M. O., & Budi, I. (2019). Multi-label hate speech and abusive language detection in Indonesian Twitter. In *Proceedings of the Third Workshop on Abusive Language Online* (pp. 46–57). Association for Computational Linguistics. <https://doi.org/10.18653/v1/W19-3506>
- Koto, F., Rahimi, A., Lau, J. H., & Baldwin, T. (2020). IndoLEM and IndoBERT: A benchmark dataset and pre-trained language model for Indonesian NLP. In *Proceedings of the 28th International Conference on Computational Linguistics* (pp. 757–770). International Committee on Computational Linguistics. <https://aclanthology.org/2020.coling-main.66/>
- Koto, F., Lau, J. H., & Baldwin, T. (2021). IndoBERTtweet: A pretrained language model for Indonesian Twitter with effective domain-specific vocabulary initialization. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing* (pp. 10660–10668). Association for Computational Linguistics. <https://aclanthology.org/2021.emnlp-main.833/>
- LLC, C. T. (2025). *Natural Language Processing with Python: Master Text Processing, Language Modeling, and NLP Applications with Python's Powerful Tools*. Packt

Publishing.

https://www.google.co.id/books/edition/Natural_Language_Processing_with_Python/EG4_EQAAQBAJ

- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press. <https://nlp.stanford.edu/IR-book/>
- Prahasto, G. S., & Setiawan, E. B. (2025). Twitter social media-based sentiment analysis using Bi-LSTM method with genetic algorithms optimization. *Khazanah Informatika*, 11(1), 20–26. <https://doi.org/10.23917/khif.v11i1.3959>
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing* (pp. 843–857). <https://aclanthology.org/2020.aacl-main.85/>
- Zhang, Z., Zhao, J., Zhao, J., & Zeng, X. (2024). A study of the class imbalance problem in abusive language detection. In *Proceedings of the 8th Workshop on Online Abuse and Harms (WOAH 2024)* (pp. 38–51). Association for Computational Linguistics. <https://aclanthology.org/2024.woah-1.4/>
- Cahyawijaya, S., Winata, G. I., Wilie, B., Vincentio, K., Li, X., Lim, Z. Y., Soleman, S., Putra, I., Mahendra, R., Aris, A., & Purwarianti, A. (2021). IndoBART and IndoGPT: Pre-trained language models for Indonesian language generation. *arXiv preprint arXiv:2104.08200*. <https://arxiv.org/abs/2104.08200>
- Scikit-learn developers. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html>